

Lectura 5.1: Problemas inversos y paramétricos

Introducción a las redes neuronales informadas por física
Especialización en Inteligencia Artificial - B32025

Outline

- Introducción problemas inversos
- Problemas paramétricos
- Implementaciones

Problemas inversos

En general, los problemas inversos **no** satisfacen al menos una de las “condiciones de Hadamard”:

- Existencia
- Unicidad
- Estabilidad

Son, entonces, problemas “**mal colocados**” (ill-posed problems)

Problemas inversos típicos


Problemas de estimación de parámetros

Difusividad desconocida

$$\begin{aligned}\frac{\partial T}{\partial t} &= \alpha \frac{\partial^2 T}{\partial x^2}, \quad x \in [0, L], t \in (0, t_f] \\ T(0, t) &= T(L, t) = T_{bc}, \quad t \in (0, t_f] \\ T(x, 0) &= T_0 \sin(\pi x/L) + T_{bc}, \quad x \in [0, L]\end{aligned}$$

Problemas de estimación de funciones

Flujo de calor desconocido



Otros problemas: estimación de fuentes térmicas, resistencias de contacto, etc.



Problemas inversos

- En este tipo de problemas, **los datos siempre tienen ruido**
- Su resolución computacional requiere el uso de estrategias de regularización (L2, dropout, otras)
- Los problemas de estimación de función pueden incluir los casos donde los parámetros físicos sean dependientes de la temperatura



Problemas inversos - Caso de la literatura

Sean las ecuaciones de NS, donde λ_1 y λ_2 son parámetros desconocidos:

$$\begin{aligned}u_t + \lambda_1(uu_x + vu_y) &= -p_x + \lambda_2(u_{xx} + u_{yy}), \\v_t + \lambda_1(uv_x + vv_y) &= -p_y + \lambda_2(v_{xx} + v_{yy}), \\u_x + v_y &= 0.\end{aligned}$$



Problemas inversos - Caso de la literatura



Correct PDE	$u_t + (uu_x + vu_y) = -p_x + 0.01(u_{xx} + u_{yy})$ $v_t + (uv_x + vv_y) = -p_y + 0.01(v_{xx} + v_{yy})$
Identified PDE (clean data)	$u_t + 0.999(uu_x + vu_y) = -p_x + 0.01047(u_{xx} + u_{yy})$ $v_t + 0.999(uv_x + vv_y) = -p_y + 0.01047(v_{xx} + v_{yy})$
Identified PDE (1% noise)	$u_t + 0.998(uu_x + vu_y) = -p_x + 0.01057(u_{xx} + u_{yy})$ $v_t + 0.998(uv_x + vv_y) = -p_y + 0.01057(v_{xx} + v_{yy})$


Problemas inversos - Implementación

Problemas paramétricos

- Es posible construir PINNs que tengan más variables de entrada que las correspondientes a la definición de los puntos de colocación
- Se construyen mediante la incorporación de “features” adicionales en la red neuronal
- El modelo PINN así entrenado ofrece una “metasolución” válida para diferentes valores de la variable adicional, dentro del rango especificado

Problemas paramétricos - Ejemplo

Problema de conducción de calor en
régimen transiente con fuente térmica
Gaussiana móvil



Descripción	Valor
Densidad ρ (kg mm^{-3})	$7,6\text{e}-6$
Conductividad térmica k ($\text{W mm}^{-1} \text{K}^{-1}$)	$0,025$
Capacidad térmica específica c_p ($\text{J kg}^{-1} \text{K}^{-1}$)	658
Difusividad térmica α ($\text{mm}^2 \text{s}^{-1}$)	$4,80215$
Longitud del dominio L (mm)	100
Ancho del dominio H (mm)	50
Tiempo total del análisis transiente t_f (s)	50
Temperatura inicial T_0 (K)	273
Potencia total de la fuente Gaussiana $\dot{Q}_T$ (W)	$62,83185$
Velocidad de la fuente v (mm s^{-1})	2
Radio característico r_0 (mm)	$0,02 \text{ a } 10,0$

“Radio
característico”

Problemas paramétricos - Formulación

$$\frac{\partial u}{\partial \tau} = \frac{\partial^2 u}{\partial \xi^2} + \frac{\partial^2 u}{\partial \eta^2} + \dot{Q}(\xi, \eta, \tau), \quad \forall (\xi, \eta) \in \Omega^*, \tau \in (0, \tau_f]$$

$$\nabla u(\xi, \eta, \tau) = 0, \quad \partial\Omega^*, \quad 0 < \tau \leq \tau_f$$

$$u(\xi, \eta, 0) = u_0, \quad \forall (\xi, \eta) \in \Omega^*, \tau = 0$$

$$\dot{Q}(\xi, \eta, \tau) = \frac{\dot{Q}_T^*}{\pi \rho_0^2} e^{-(\xi - v^* \tau)^2 / \rho_0^2} e^{-\eta^2 / \rho_0^2}$$

**Ecuaciones de gobierno
adimensionales**

$$\xi = \frac{x}{L}, \quad \eta = \frac{y}{L}, \quad \rho_0 = \frac{r_0}{L}, \quad \tau = \frac{k}{\rho c L^2} t \equiv Fo,$$

Variables adimensionales

$$u = \frac{T}{T_0},$$

$$\dot{Q}_T^* = \frac{\dot{Q}_T}{k T_0} \quad \text{y} \quad v^* = \frac{\rho c L}{k} v,$$

Problemas paramétricos - Datasets

$$X_i = \begin{pmatrix} x_1 & y_1 & r_{01} & t_1 \\ x_2 & y_2 & r_{02} & t_2 \\ \vdots & \vdots & \vdots & \vdots \\ x_{N_i} & y_{N_i} & r_{0N_i} & t_{N_i} \end{pmatrix}$$

$i = \text{PDE, BC, IC}$

Rangos de variación:

$$x \in [0, 100\text{mm}]$$


$$y \in [0, 50\text{mm}]$$

$$r_0 \in [1\text{mm}, 10\text{mm}]$$

$$t \in [0, 50\text{s}]$$

$$\begin{aligned} X_{\text{PDE}} &= \{P_i = (\xi_i, \eta_i, \tau_i, \rho_{0i}) / P_i \in \Omega \times (0, \tau_f] \times [\rho_0^{\text{inf}}, \rho_0^{\text{sup}}]; i = 1, \dots, N_{\text{PDE}}\}, \\ X_{\text{BC}} &= \{Q_i = (\xi_i, \eta_i, \tau_i, \rho_{0i}) / Q_i \in \partial\Omega \times (0, \tau_f] \times [\rho_0^{\text{inf}}, \rho_0^{\text{sup}}]; i = 1, \dots, N_{\text{BC}}\}, \\ X_{\text{IC}} &= \{R_i = (\xi_i, \eta_i, 0, \rho_{0i}) / R_i \in \Omega \cup \partial\Omega \times [\rho_0^{\text{inf}}, \rho_0^{\text{sup}}]; i = 1, \dots, N_{\text{IC}}\}. \end{aligned}$$

Problemas paramétricos - Datasets




$$N_{\text{PDE}} = 40\,000$$

$$N_{\text{BC}} = 10\,000$$

(puntos de colocación
para $t > 0$)

Problemas paramétricos - Arquitectura

Módulo Informado por Física






Problemas paramétricos - Modelos evaluados


- FC-FFNN con 4 entradas y una salida.
- Función de activación $\tanh()$ en todas las unidades
- En la unidad de salida se aplica función “softplus”: $f(x) = \beta^{-1} \log(1 + e^{\beta x})$.
- Modelos ensayados:

Modelo	Arquitectura		Tipo	Optimizador	Épocas
	NCO	NNxC		lr	
M1	5	50	BFGS	1,0	15 000
M2	5	50	Adam+BFGS	$5e-4 1,0$	3 500 + 10 000
M3	5	100	BFGS	1,0	15 000
M4	6	150	BFGS	1,0	15 000
M5	6	200	BFGS	1,0	15 000


Resultados - Radio característico $r_0 = 2 \text{ mm}$






Modelo	Arquitectura		Tipo	Optimizador	
	NCO	NNxC		lr	Épocas
M1	5	50	BFGS	1,0	15 000
M2	5	50	Adam+BFGS	$5e-4 1,0$	3 500 + 10 000
M3	5	100	BFGS	1,0	15 000
M4	6	150	BFGS	1,0	15 000
M5	6	200	BFGS	1,0	15 000




Resultados - Radio característico $r_0 = 5\text{ mm}$






Modelo	Arquitectura		Tipo	Optimizador	
	NCO	NNxC		lr	Épocas
M1	5	50	BFGS	1,0	15 000
M2	5	50	Adam+BFGS	$5e-4 1,0$	3 500 + 10 000
M3	5	100	BFGS	1,0	15 000
M4	6	150	BFGS	1,0	15 000
M5	6	200	BFGS	1,0	15 000



Resultados - Radio característico $r_0 = 8 \text{ mm}$




Modelo	Arquitectura		Tipo	Optimizador	
	NCO	NNxC		lr	Épocas
M1	5	50	BFGS	1,0	15 000
M2	5	50	Adam+BFGS	$5e-4 1,0$	3 500 + 10 000
M3	5	100	BFGS	1,0	15 000
M4	6	150	BFGS	1,0	15 000
M5	6	200	BFGS	1,0	15 000



Problemas paramétricos - Comentarios sobre el caso evaluado

- El modelo PINN así entrenado permitió obtener soluciones paramétricas en relación con el parámetro de “radio característico”, válidas para el rango $r_0 \in [1\text{mm}, 10\text{mm}]$
- Se manifiestan “modos de falla” comentados en clase
- Las pruebas realizadas con $r_{\{0\}}^{\{inf\}} < 1\text{ mm}$ no permitieron entrenar el modelo. Ej: **solución ground-truth con $r_0=0.2\text{ mm}$**



Problemas paramétricos - Implementación (Colab)

Retomemos el problema de conducción de calor 1D en régimen transiente:

$$\begin{aligned}\frac{\partial T}{\partial t} &= \alpha \frac{\partial^2 T}{\partial x^2}, \quad x \in [0, L], \quad t \in (0, t_f] \\ T(0, t) &= T(L, t) = T_{bc}, \quad t \in (0, t_f] \\ T(x, 0) &= T_0 \sin(\pi x / L) + T_{bc}, \quad x \in [0, L]\end{aligned}$$

Vamos a implementar un problema paramétrico para valores de $k \in [200.0, 300.0]$

¿Dudas o
preguntas?