

Caso de estudio: Reconstrucción del campo de flujo en una cavidad cuadrada*

Dr. Ing. Benjamin A. TOURN - Ing. Carlos G. MASSOBRIO

5to bimestre 2025

1 Enunciado

El flujo en una cavidad cuadrada (*lid-driven square cavity*) es un caso estándar utilizado para verificar la precisión de métodos computacionales novedosos para resolver las ecuaciones de Navier-Stokes incompresibles. En estado estacionario, el campo de flujo en la cavidad que ocupa la región $\Omega = [0, 1] \otimes [0, 1]$ se describe mediante las siguientes ecuaciones de gobierno:

$$(\mathbf{u} \cdot \nabla)\mathbf{u} = -\nabla p + \frac{1}{\text{Re}}\nabla^2\mathbf{u}, \quad \text{en } \Omega \quad (1.1a)$$

$$\nabla \cdot \mathbf{u} = 0, \quad \text{en } \Omega. \quad (1.1b)$$

con condiciones de borde prescritas tal como se muestra en la figura 1. Allí se aprecian condiciones tipo *no-slip* (no deslizamiento) en las fronteras laterales e inferior, mientras que la frontera superior se mueve con velocidad constante en la dirección $+x$.




Figura 1: Dominio y condiciones de borde para flujo en la cavidad.

*Basado en la contribución del Dr. Khemraj Shukla de Brown University para curso NVIDIA Modulus

2 Dataset

La carpeta “Re-100” reúne los archivos `pressure.mat` y `velocity.mat` que contienen los campos de presiones p y velocidades $\mathbf{u} = [u, v]^T$ respectivamente, obtenidos mediante el método de elementos finitos (MEF) sobre una malla uniforme de cuadrángulos. La figura 2 muestra los campos en cuestión. Dichas soluciones se deberán considerar como *ground-truth* para los objetivos de este trabajo.




Figura 2: Campos de velocidades y presión obtenidos mediante el MEF.

3 Trabajos prácticos

3.1 TP N°1: Puntos de colocación

Los puntos de colocación para entrenar un modelo PINN se definen en relación con los términos que se pretenden incluir en la función de pérdida del modelo. Para el caso en cuestión, existirán puntos sobre los que se deberán computar los residuos r_{pde} y r_{bc} de las PDE de gobierno y de las condiciones de borde, respectivamente. De esta manera, el dataset de entrenamiento queda conformado como una colección de sub-conjuntos de puntos de colocación, cada uno relacionado con el término correspondiente en la función de pérdida.

Realizar las siguientes actividades:

1. Definir los sub-conjuntos de puntos de colocación según el tipo de residuo que deberían incluir en la función de pérdida, y teniendo en cuenta la configuración geométrica del problema. Utilizar $N_{pde} = 1000$ y $N_{bc} = 100$. Implementar estrategias de muestreo tipo grillas regulares y muestreo aleatorio.
2. Graficar los puntos de colocación. Emplear un color distinto según el subconjunto al que pertenecen.
3. Inclusión de datos rotulados: considere la existencia de $N_{data} = 10$ puntos (x, y) en el dominio (no constituyen específicamente “puntos de colocación”) sobre los que se cuenta con mediciones de presión p y velocidades (u, v) , distribuidos de forma aleatoria. Construya el dataset correspondiente, incluyendo los *labels* (para ello, utilice los datos de presión y velocidad suministrados). ¿Qué le sugiere la estructura de datos de este dataset complementario respecto a los sub-conjuntos de puntos de colocación, en relación con los *labels*?

4. Para pensar: el sub-conjunto de los puntos de colocación correspondientes a la PDE de la ecuación de gobierno, ¿debería o no contener puntos definidos sobre las fronteras físicas del dominio?

3.2 TP N°2: Modelado PINN

La implementación básica de un esquema vanilla PINN para realizar el cómputo “directo” de las variables dependientes en estudio (en este caso, la presión p y velocidades u y v) incluye como mínimo los siguientes aspectos:

- Construcción de los datasets de entrenamiento a partir de los subconjuntos de puntos de colocación (aspecto abordado en el TP N°1).
- Definición de la arquitectura de la red neuronal FC: número de variables de entrada (depende de las variables independientes el problema) y de salida (depende de las variables dependientes a modelar), número de capas (profundidad), ancho (número de neuronas por capa) y funciones de activación.
- Desarrollo de las rutinas para calcular los residuos, que implica el uso del esquema de autodiferenciación.
- Elección del optimizador y de los hiperparámetros correspondientes (*learning rate*, *weight decay*, etc).
- Inicialización de los parámetros entrenables (usualmente mediante estrategias de Xavier o He).
- Definición de otros hiperparámetros (cantidad de *epochs*, pesos de los términos de la función de pérdida, etc).
- Proceso de entrenamiento (*loop* sobre *epochs*): en cada *epoch* se debe computar la función de pérdida total como suma ponderada de las contribuciones de la pérdida para cada sub-conjunto del dataset de entrenamiento.
- Impresión en pantalla de los *logs* de entrenamiento cada N *epochs*.
- Elaboración de los gráficos de evolución de las funciones de pérdida de los residuos y la función de pérdida total al finalizar el entrenamiento.

Realizar las siguientes actividades:

1. Implementar una rutina que incluya los pasos enumerados previamente. Tomar como referencia las implementaciones provistas por la cátedra (ver *notebooks* de Colab). Prestar especial atención al cómputo de las derivadas de la presión p y velocidades u y v en función de las variables independientes, y a la construcción de los residuos correspondientes.
2. Resolver el sistema de ecuaciones del enunciado mediante PINN, sin emplear datos rotulados. Utilizar muestreos aleatorios tanto para el residuo de las PDE como para las condiciones de borde. Utilizar $N_{\text{pde}} = 10000$ y $N_{\text{bc}} = 1000$.
3. Calcular la norma-2 del error entre los valores de presión p y velocidades (u, v) que predice el modelo y sus correspondientes valores *ground-truth*. Para ello, computar los campos de presión y velocidad en la misma grilla de puntos que la empleada en la solución de referencia.
4. Graficar el error absoluto entre los valores de presión p y velocidades (u, v) que predice el modelo y sus correspondientes valores medidos (utilizando la misma grilla que en el punto anterior).
5. En base al grado de convergencia obtenido durante el entrenamiento y los gráficos de error ¿Considera que el modelo desarrollado es suficientemente “bueno” para predecir los campos de presión y velocidad? ¿Qué fallas observa? ¿Qué aspectos positivos destaca? ¿Considera que los hiperparámetros que definió

son adecuados? ¿Puede mejorarse el desempeño del modelo? En caso afirmativo ¿Qué acciones de mejoras se podrían implementar?

3.3 TP N°3: Influencia de las estrategias de muestreo de puntos de colocación

En el TP N°2 se indicó únicamente que el muestreo de puntos de colocación debía ser aleatorio. En esta oportunidad se analizará cómo influyen las distintas estrategias de muestreo de puntos de colocación en el desempeño del modelo PINN.

Actividades a realizar:

1. Para el modelo PINN desarrollado en el TP N°2, implementar las siguientes estrategias de muestreo para la construcción de los subconjuntos de puntos de colocación: muestreo aleatorio uniforme, muestreo por el método de hipercubo latino (LHS), y por muestreo adaptativo basado en residuos (estrategia RAD). En este último caso, utilice los residuos de las dos ecuaciones de balance de cantidad de movimiento como métrica para llevar a cabo la estrategia.
2. Para cada estrategia, preparar tres datasets con las siguientes cantidades de puntos:
 - Primer dataset con $N_{pde} = 1000$ y $N_{bc} = 100$.
 - Segundo dataset con $N_{pde} = 10000$ y $N_{bc} = 1000$.
 - Tercer dataset con $N_{pde} = 100000$ y $N_{bc} = 10000$.
3. Entrenar el modelo PINN para las nueve configuraciones de datasets preparados en el ítem 2. Con el fin de realizar una comparación “justa”, en todos los casos deberá utilizar la misma configuración de hiperparámetros (tamaño de red, optimizador, cantidad de epochs, etc.), y defina el criterio de selección de dichos valores. Utilice un valor $\lambda_{bc} = 10$ para el peso de la componente de la función de pérdida asociada al residuo de las condiciones de borde de velocidad. Calcular en cada caso la norma-2 del error de la misma manera que se realizó en el ítem 3 del TP N°2.
4. **Convergencia en cantidad de puntos de colocación.** Grafique los valores previamente calculados de la norma-2 del error en función del tamaño del dataset, en una gráfica doble logarítmica (loglog). ¿Observa un patrón de convergencia? ¿Es posible reportar una tasa de convergencia estable? ¿Cuál de todas las configuraciones alcanzó el mejor desempeño? ¿Es consistente esta conclusión con lo que usted esperaba? ¿Porqué si o porqué no?

3.4 TP N°4: Resolución del problema inverso

Una de las virtudes de PINN es abordar, a diferencia del MEF, la resolución del problema inverso. Esto es, conocidas las variables dependientes en partes específicas en el dominio del modelo físico, se entrena al modelo PINN para realizar el cómputo de algunas de sus partes constitutivas que son desconocidas. Para ello, solo se requiere considerarlas como elementos a entrenar en la red neuronal. En este caso, sí es necesario utilizar un dataset, el cual puede generarse a partir de mediciones experimentales o simulaciones numéricas.

Para este Trabajo Práctico se asume que el número de Reynolds en la ecuación 1.1 es desconocido. Las actividades a realizar son las siguientes:

1. Construir tres datasets a partir de los datos *ground-truth* del problema. Para ello, deberán extraer los valores de u y p de grillas regulares cuadradas con las siguientes configuraciones:

- a) Cuadrado centrado en Ω de $0,25 \times 0,25$.
 - b) Cuadrado centrado en Ω de $0,50 \times 0,50$.
 - c) Cuadrado centrado en Ω de $0,75 \times 0,75$.
2. Obtener el valor del número de Reynolds para cada configuración.
3. Comparar los resultados obtenidos con cada conjunto de datos. ¿Qué conclusiones pueden extraerse sobre la influencia de la distribución espacial de las muestras en el comportamiento de u y p ?